

Safe Eye · 양시영 · 류상균 · 채윤식 · 박희연

On-Device AI 기반 산업 현장 안전 감지 시스템

고정 카메라 비전으로 작업자의 PPE(안전모·안전조끼) 미착용과
위험 구역 근접을 네트워크 없이 실시간 감지

Raspberry Pi 5 + Camera Module | YOLO · MobileNetV3 · TFLite | 2026

목차

00

팀 구성

01

주제 및 결과 요약

02

개발 목표 및 개발 결과

03

핵심 기술

04

기대 효과

05

향후 연구 과제

06

프로젝트 수행 후기

팀 구성

양시영

시스템 및 아키텍처 설계,
PPE 모델 정량적 성능 평가

류상균

PPE OD 객체 분류 모델 설계 및 학습,
하드웨어 및 임베디드 구동 시스템
구현

채윤식

PPE MLC 모델 설계 및 학습,
위험 지역 감지 시스템

박희연

학습 데이터 및 성능 평가 데이터
전처리,
시스템 통합 및 프론트엔드 위젯

왜 이 시스템인가, 그리고 무엇을 확인했는가

배경

산업재해 사망자는 매년 800명대 — 추락·끼임이 다수. 사람 감독만으로는 24시간·전 구역의 사각지대를 메울 수 없다.
네트워크가 불안정한 현장일수록 위험하다 → 단말에서 추론이 끝나는 On-Device AI 안전 비전이 필요하다.

무엇을 만들었나

- IR 센서 트리거 → Person Detector → PPE 판별(OD/MLC) + 위험구역 판정(OD)을 단말에서 동시 수행
- 실시간 결과를 카메라 오버레이 화면과 음성으로 현장에 즉시 전달 — On-Device AI 안전 경고 시스템 구현
- PPE 검출 정확도를 높이기 위해 OD·MLC 두 접근법을 정량 비교하고, 환경별 최적 조합으로 하이브리드 적용

올인원

PPE 판별 + 위험구역 접근 판정 +
오버레이·음성 경고 — 단말 하나로 완결

On-Device

네트워크 없이 단말 추론 — 통신 단절
환경에서도 안전 판단 지속

AP 0.943

PPE 판별 정량 평가 — 하이브리드
모델로 환경별 최적 성능 확보

목표 대비 달성 현황

개발 목표	결과
IR 센서 기반 작업자 감지 트리거	달성 — 감지 시에만 AI 추론 활성화
실시간 사람 감지 (YOLO)	달성 — OD·MLC·Danger Zone가 공유
PPE 판별 — OD·MLC 정량 비교	달성 — 환경별 최적 모델 선정
OD 기반 위험 구역 접근 판정	달성 — 사람 좌표 + 위험 영역 교차 판정
카메라 오버레이 + 음성 경고 출력	달성 — 현장 즉시 시각·청각 알림
On-Device 통합 동작	달성 — 단말 하나로 모든 기능 완결

KPI 달성 현황

- ✓ **헬멧 정확도 $\geq 80\%$**
OD 91.6% · MLC 83.7%
- ✓ **조끼 정확도 $\geq 70\%$**
OD 81.8% · MLC 81.8%
- ✓ **실시간 추론 ≥ 5 FPS**
Pi5 기준 6 FPS 이상
- ✓ **시스템 통합 동작**
IR → 감지 → 판별 → 경고 단일 흐름

*PPE 정확도뿐 아니라 시스템 전체 기능
통합까지 달성*

시스템 구성 — IR 트리거부터 현장 경고까지



③ PPE 판별과 ④ 위험구역 판정은 **동시 수행** — 단말 하나에서 두 안전 항목을 병렬로 평가

IR 트리거 효율화

상시 추론 대신 사람 접근 시에만 AI 활성화
— 전력·자원 절약, 단말 부담 감소

단말 통합 처리

PPE 판별과 위험구역 판정을 단말 하나에서
동시 수행, 네트워크 불필요

현장 즉시 경고

감지 → 판정 → 시각·청각 알림까지 단일 흐름,
작업자에게 실시간 전달

시연 영상



PPE 판별 — 두 가지 접근법 비교

접근법 1

OD (Object Detection) 방식 — 객체 탐지

YOLO OD가 helmet-vest bbox를 직접 검출 > 각 person bbox에 귀속 > 착용 여부 판정

- PPE를 한 번에 검출 — 이미지당 추론 1회 (인원수 무관)
- 다인원 환경에서도 일정한 FPS 유지
- vest 검출 정확도가 학습된 OD 모델 품질에 직접 의존

접근법 2

MLC (Multi Label Classification) 방식 — 분류

person bbox 상체 크롭 > MobileNetV3 멀티 라벨 분류 > 헬멧·조끼 각각 착용 확률

- 사람 단위 크롭을 분류 — 사람 수만큼 추론 반복
- 1인 환경에서 정확도 우위 (특히 vest)
- 다인원에서 FPS 선형 하락 + 크롭 오염 가능성

공정 비교 방법

동일한 person 박스를 두 방식이 공유 · 독립 GT 데이터셋(11클래스)으로 평가 — OD 학습셋과 분리하여 데이터 누수 회피

두 접근법의 파이프라인 비교



데이터셋 선정과 MLC 라벨 변환

데이터셋 선정

- 공개 PPE 데이터셋은 대부분 객체 탐지(OD) 학습용
- 선정 데이터셋 — 모두 YOLO OD 형식
 - Kaggle HardHat-Vest Dataset
 - Construction Site Safety (Roboflow)
 - Roboflow Universe PPE
- 약 22,000장 · 클래스 helmet-vest-no-helmet

MLC를 위한 추가 작업

OD 형식 라벨

이미지별 PPE bbox



MLC 형식 라벨

1인 1이미지 + 이진(착용/미착용) 라벨

- 1 사람 검출 & 크롭** YOLO로 person bbox 검출 → 사람별 이미지로 분할
- 2 겹침 필터** 다른 사람이 섞인 크롭 제거 (Containment Ratio)
- 3 PPE 라벨 귀속** OD bbox 라벨을 각 크롭에 매칭 → helmet-vest 이진 라벨 부여
- 4 충돌 제거 & 저장** 상반된 라벨 제거 → 크롭 이미지 + 이진 라벨 CSV 완성

OD는 원본 데이터셋 그대로 사용 — MLC 변환 시 **22,000장 자동 크롭·라벨링 + 중복 매칭·저해상도 크롭 필터링 + 파일명 기반 상태 코드화(11/10/01/00)**

MLC 학습 데이터 전처리 — 클래스 균형 잡기

OD에서 변환한 1인 크롭은 상태 분포가 극단적 — 그대로 학습하면 다수 클래스에 편향. 균등 샘플링과 Stratified 분할로 안정 학습 기반을 만든다.

문제

상태 코드별 데이터 분포가 극단적

HV 코드	의미	샘플 수
10	헬멧 O · 조끼 X	≈ 25,000장
11	헬멧 O · 조끼 O	≈ 4,000장
00	헬멧 X · 조끼 X	≈ 20,000장
01	헬멧 X · 조끼 O	≈ 900장

해결

균등 샘플링으로 학습 안정성 확보

- 희소 클래스 전량 사용**
데이터가 적은 01·00 코드는 가용 샘플 전부 학습에 투입
- 다수 클래스 균등 샘플링**
10·11 코드는 클래스별 최대 1,000장으로 균등하게 다운샘플링
- 초기 시도와 비교**
Class Weight · Augmentation 단독 적용은 학습 불안정 · 과적합 발생

Stratified 3-Way 분할

Train 70% · Validation 15% · Test 15% · 검증셋 기반 EarlyStopping으로 과적합 방지 및 일반화 성능 확보

Train 70%

Val 15%

Test 15%

GT 평가 데이터셋 전처리 — 누수 없는 공정 비교

OD 학습셋과 분리된 11클래스 GT 데이터셋을 별도 구축. 인원수·라벨 균형을 모두 만족하는 100장을 선별해 OD·MLC 동일 조건에서 평가한다.

01

전략적 샘플링

인원수 · 라벨 균형 동시 충족

- Greedy 알고리즘으로 인원수(1~2명 vs 3인 이상)와 헬멧·조끼 상태 라벨 균형을 동시에 만족하는 원본 100장 선별
- Few 그룹 496장 / Many 그룹 165장 · 총 평가 인원 1,477명

02

데이터 누수 방지

Train · Test 물리적 격리

- 테스트셋 원본 100장에서 파생된 모든 크롭 이미지를 MLC·OD 학습셋에서 물리적으로 제거
- OD 학습셋과 다른 출처의 11클래스 라벨을 사용해 평가의 객관성 확보

03

구간별 정량 평가

환경별 분리 분석

- Small(1~2명) · Large(3명 이상) 구간으로 분리해 환경별 정확도와 FNR 차이를 분석
- 혼동행렬(Confusion Matrix) 도출로 미경고·오경고 케이스를 정량적으로 확인

공정 비교의 전제

동일한 yolo11m person 박스를 OD · MLC가 공유 — detector 차이로 인한 편향 제거. 두 방식이 같은 평가셋같은 사람 박스를 보므로 상대 비교 결과는 신뢰할 수 있다.

PPE MLC 모델 학습 — MobileNetV3Large

엣지 추론에 맞춘 경량 백본 + Multi-Label 헤드. 클래스 불균형은 데이터 측면에서 해결한 뒤 학습 안정성을 확보했다.

모델 구조

MobileNetV3Large + Sigmoid × 2



백본 ImageNet 사전학습 가중치 사용 · 마지막 Dense 재학습

출력 helmet_prob · vest_prob 두 확률 (0.5 임계값)

Loss Binary Cross-Entropy · Adam Optimizer

학습 안정화 과정

불균형 → 시도 → 해결

문제 상태 코드별 분포가 극단적 · 다수 클래스 편향 학습

시도 Class Weight 조정 · Data Augmentation → 학습 불안정 · 과적합 발생

해결 데이터 추가 수집 + 균등 샘플링(클래스별 최대 1,000장)

✓ 학습 결과

Validation 정확도 — **헬멧 91.0%** · **조끼 91.8%** (KPI 80% 달성)


균등 샘플링 적용 직후 학습이 안정화되었고, 헬멧·조끼 양쪽에서 KPI 80%를 안정적으로 상회했다.

PPE MLC 학습 결과 — 균등 샘플링 전 / 후

데이터 분포 균등화 직후 검증 정확도와 손실이 동반 안정화 — 불균형 단독 학습의 한계를 데이터 측면에서 해결한 결과.


BEFORE

샘플링 전 — 불균형 데이터



AFTER

샘플링 후 — 균등 데이터



✓ 학습 곡선 안정화
Train · Val 격차 축소로 과적합 완화

✓ Loss 동반 수렴
Val Loss가 epoch 후반까지 안정 유지

✓ KPI 80% 안정 상회
헬멧 91.0% · 조끼 91.8% 달성

PPE OD 학습 데이터 정리 — 공개 데이터 검수

공개 PPE 데이터셋은 양은 많지만 라벨 품질이 일정하지 않아, 검수와 라벨을 통일하여 학습 가능한 형태로 정리

STEP 01

데이터 품질 이슈 확인

- 공개 PPE 데이터는 양은 많지만 이미지와 라벨 파일이 맞지 않는 경우 다수
- 출처별 클래스명 정의 제각각 — 통일 없이 학습 시 즉시 오류 발생
- MLC와 OD가 같은 원본을 쓰지만 라벨 체계가 분리돼 있어 정합성 문제

STEP 02

검수 및 라벨 통일

- 이미지 ↔ YOLO 라벨 매칭 일치 여부 직접 확인 및 수정
- Yolo11n Person Class로 크롭된 데이터 4,000장 추가 검수 완료
- MLC 모델과 helmet · vest 라벨 체계 통일 (no-vest는 부재 추론)

STEP 03

학습 가능 데이터 최종 구성

- 라벨: helmet · vest 2클래스 (YOLO 형식)
- Train 24,941장 / Validation 1,200장
- Roboflow Universe · Construction Site Safety 등 다출처 통합

핵심 포인트 라벨 오류와 클래스 불일치를 직접 검수하고, 추가 검증 데이터 **4,000장**으로 YOLO11n 학습 데이터의 품질을 보강 — 학습 안정성과 정확도의 기반을 마련

PPE OD 학습 결과 — YOLO11n · Recall 우선

안전 시스템 특성상 미경고(미착용 → 착용 오판) 위험이 더 크다 → Recall을 우선 지표로 추적

Best Epoch

42

Best mAP50

0.923

Last Recall

0.885


Last mAP50-95

0.785

검증 지표 변화 · mAP50 · Precision · Recall 모두 epoch 40 부근에서 수렴

검증 지표 변화

mAP50, Precision, Recall · 높을수록 좋음



ENVIRONMENT

학습 모델 환경

- YOLO11nano · Image Size 416 학습 / 320 추론
- 추론 Pixel 수 1.7배 차이로 실시간 동작을 위한 경량화 실시


RESULT

학습 결과 요약

- 마지막 Epoch Recall **88.5%**
- Recall 우선 — 미경고를 가장 강하게 억제
- mAP50 — 92%

전체 성능 비교 — OD vs MLC

판별 정확도 (%) — overall



인원별 상세 — 환경 × 모델 × 항목

환경	Helmet OD	Helmet MLC	Vest OD	Vest MLC
single (1인)	92.6%	91.6%	79.6%	90.8%
crowd (3인 이상)	92.8%	89.6%	73.6%	77.8%
전체 (overall)	92.8%	90.4%	76.0%	83.0%

OD 우위

MLC 우위

색 패턴 — 헬멧 = OD 일관 우세, 조끼 = MLC 일관 우세 (양쪽 환경 모두). **정확도 외에 실시간성(FPS)이 파이프라인 결정의 두 번째 축**
→ 다음 슬라이드

파이프라인 결정 — 정확도 + 실시간성

환경	평균 인원	Vest 정확도 우위	FPS (PC 기준)	채택
single (1인)	1.19 명	MLC 90.8% vs 79.6% (+11.2%p)	MLC 3.48 / OD 3.70 (차이 미미)	MLC
crowd (3인 이상)	5.39 명	MLC 77.8% vs 73.6% (+4.2%p, 작음)	MLC 1.92 / OD 3.70 (MLC 절반)	OD


1인 환경 — 정확도 우선

vest 11.2%p 차이로 MLC 압도. FPS 차이는 미미 →
정확도 기준으로 MLC 채택

다인원 환경 — 실시간성 우선

MLC FPS 절반으로 무너짐 (3.5→1.9). 정확도 차이 작음 →
실시간성 확보로 OD 채택, vest 4.2%p 손실 감수

다인원 환경에서의 민감도 분석




1인 환경 — MLC 압도

MLC vest AP 0.943 — OD 점이 곡선 아래 명확히 위치

다인원 — 두 방식 동반 하락

MLC vest AP 0.943 → 0.835. OD precision 0.65로 떨어짐



메시지 일치

막대그래프와 PR Curve 모두 동일한 결론 — 환경별 다른 trade-off

두 모델 비교로 얻은 핵심 발견

1 클래스별 우세 모델이 다름

헬멧: OD 일관 우세 (양 환경 92~93% vs 90~92%)
조끼: MLC 일관 우세 (single 90.8% vs 79.6%, crowd 77.8% vs 73.6%)

2 다인원에서 양 모델 vest 동반 하락

OD vest 79.6% → 73.6% MLC vest 90.8% → 77.8%
다인원은 두 방식 공통 약점 — 가림작은 bbox 영향

3 MLC는 사람 수에 따라 FPS 선형 하락

single 3.48 FPS → crowd 1.92 FPS (절반)
OD는 인원 무관 3.70 FPS 일정 — 추론 구조 차이

4 MLC만 임계값 조정 가능

MLC vest 1인 AP 0.943 — PR Curve로 trade-off 조절
OD는 단일 운영 포인트 (점), 임계값 조정 불가

결론

하이브리드 파이프라인이 단일 모델 한계를 보완한다

단일 모델로는 정확도와 실시간성을 동시 만족 불가 → 1인 MLC(정확도 우선) + 다인원 OD(실시간성 우선)로 환경별 최적화

위험구역 감지 시스템 — 표지판 기반 자동 영역 설정

위험 표지판을 한 번 탐지하면 그 bbox를 확장해 위험 구역 polygon을 만들고, 작업자 발 위치가 영역 안에 들어오면 즉시 DANGER 경고를 출력한다.

동작 구조

3단계 파이프라인

- 01 YOLO11n으로 위험 표지판 탐지
고정 위치 표지판 → 30프레임마다 탐지 후 결과 캐시 재사용
- 02 표지판 bbox 기준 Danger Zone 설정
bbox를 확장해 위험 구역 polygon 생성 (설치 환경별 튜닝)
- 03 발 위치 기반 진입 판정 · 즉시 경고
person bbox 하단 중심점이 polygon 내 → DANGER 경고 발령



학습 결과 (YOLO11n · 1,915장 · img 416)

1.000

Precision

0.940

Recall

0.810

F1

0.787

mAP@0.5

⚡ 설계 포인트

표지판이 정확한 위치에 있어야 위험 구역이 올바르게 설정되므로 **Precision 100%**를 우선 최적화. 표지판은 고정 위치라는 환경 특성을 활용해 **30프레임 단위로 탐지 후 캐시 재사용** — On-Device 자원 부담 최소화.

코드 통합 및 모니터링 UI — Safe Eye 대시보드

실험 결과에 근거한 Hybrid PPE 분기 로직과 실시간 상태 패널을 단말 하나로 통합. 운용자가 한 화면에서 모든 안전 지표를 확인한다.

HYBRID PPE 판정 로직

인원수 기반 분기 구조

1명 MLC 분류 · 정밀도 우선 (특히 vest)

2명+ OD 방식 · 실시간성 + 미경고 방어


실험 결과로 도출한 환경별 최적 모델을 단일 파이프라인에서 자동 분기

실시간 모니터링 UI

Safe Eye Dashboard

- Webcam · YOLO · MobileNetV3 통합 파이프라인
- 상태 패널 — 감지 인원 · PPE 위반 · 위험 표지 · FPS
- 모듈 구조화 — config · camera · detector 분리

LIVE DASHBOARD



운용자 한 화면에서 안전 지표 전체를 실시간 확인 — 감지 인원 · PPE 위반 · 위험 표지 · DANGER ZONE 진입 여부 · 추론 FPS까지 한눈에 파악.

하드웨어 구현 — 카메라 · IR · 스피커 모듈화

AI 추론 결과를 실제 경고 동작으로 연결하고 유지보수성을 확보하기 위해 IR · 카메라 · 스피커 기능을 각각 독립 모듈로 구현

INPUT

IR 센서

IRSensor

핵심

사람 감지 트리거 — AI 추론 활성화 신호

최적화

감지되지 않을 때 YOLO 추론 자체를 중단 →
자원 낭비 최소화

효과

상시 추론 대비 평균 전력·CPU 부담 크게 감소

CAPTURE

카메라

LatestFrameCamera

핵심

카메라는 항상 켜진 상태로 유지

버퍼

가장 최신 프레임 1장만 저장 — 지연 없는 추론

효과

사람이 지나가기 전에 즉시 추론 가능, 쿨드 스타트 없음

OUTPUT

스피커

DangerSpeaker

핵심

PPE 미착용 · 위험구역 진입 음성 경고 출력

Cooldown

동일 경고 반복 방지 — 30초 간격 재발령 억제

우선순위

위험구역 경고 > PPE 경고 (안전 영향도 기준)



설계 철학

기능별 독립 모듈 — 센서 · 카메라 · 스피커가 서로의 동작을 막지 않도록 분리. 교체·테스트·확장이 단위별로 가능.

이 서비스가 현장에 가져올 변화

출발점

산업재해 사망 매년 800명대 — 사람 감독만으로 24시간·전 구역의 사각지대를 메울 수 없다

24

24시간 무중단 감시

사람 감독자가 닿지 못하는 시간·공간 상시 커버
야간·휴식 시간·외곽 작업장 사각지대 해소



사고 예방 즉시 개입

PPE 미착용·위험구역 접근을 즉시 감지
현장 음성·시각 경고로 사고 발생 전 대응



통신 단절 환경 작동

On-Device 추론 — 네트워크 없이 단말에서 완결
공장 지하·외곽 등 통신 불안정 구간에서 강점



확장 가능한 안전 플랫폼

동일 파이프라인 위에 화재·낙상·장비 점검 등 추가 기능
확장 가능
현장별 위험 항목 맞춤 운영

다음 단계에서 풀어야 할 것

하이브리드는 현 시점 최대 성능을 위한 실험적 구조 — 제품화는 Person·PPE(OD)·Danger 통합 단일 모델 방향으로

REMAINING WORK

남은 작업 — 기술 완성도

01 OD 단일 모델로의 통합

Epoch 추가 학습으로 vest 정확도 +9.6%p 확인 — 두 모델 병행보다 OD 개선에 집중

02 다인원 환경 vest 정확도 개선

가림·작은 bbox 대응을 위한 데이터 보강 및 다중 프레임 정보 활용 검토

03 YOLO INT8 양자화 안정화

Pi5 배포 시 OD 정확도 손실 최소화 — QAT(Quantization-Aware Training) 적용

04 위험구역 자동 캘리브레이션

현재 bbox 확장계수가 설치 환경마다 수동 튜닝 필요. 카메라 설치 시 자동 측정·보정 알고리즘 개발

PRODUCTIZATION

서비스 출시 시 추가

01 다양한 현장 환경 대응

조명·각도·작업복 색상 다양성 확보 — 실제 현장 데이터로 fine-tuning

02 위험구역 동적 설정

현장마다 위험 영역 다름 — 관리자가 카메라 뷰에서 직접 영역 지정

03 관제 시스템 연동

이벤트 로그·스냅샷 외부 전송, 관리자 대시보드 및 알림 통합

04 운영 안정성·인증

산업안전 인증, 장기 운영 신뢰성 검증, 다중 카메라 동시 처리 확장

프로젝트를 진행하며 배운 것

기획을 현실에 맞게 좁히는 결단

이동 로봇 구상에서 고정 카메라 비전 모듈로 범위를 재설계 — '무엇을 빼느냐'가 완성도를 결정했다.

모델만 잘 만든다고 끝이 아니다

detector·크롭·양자화 mismatch를 잡는 과정에서, 학습·추론 파이프라인의 일치가 정확도를 좌우함을 체감했다.

비교 실험은 평가 설계가 절반

Ground Truth 자동 생성, 동일 조건 공유, 안전 관점 지표 선택 — 평가 방법론이 모델만큼 중요했다.

OD 학습량이 결과를 좌우

동일 데이터·코드에서 OD epoch 차이(20→60)만으로 vest 정확도 9%p 변동을 확인. 공정한 모델 비교의 전제 조건을 알게 됨.

협업의 현실

다른 팀원의 전처리 코드를 정확히 재현하는 일의 어려움, 그리고 그것을 맞췄을 때 결과가 달라지는 것을 경험했다.

Q & A

평가 방법론 메모

정량 평가 설정

데이터셋 — 11클래스 독립 평가셋 (Helmet/Vest 긍정·부정 라벨 포함). OD 학습셋과 분리하여 데이터 누수 회피.

표본 — single (1인 환경) 496장 / 588명, crowd (3인 이상) 165장 / 889명. 총 1,477명 평가.

공정 비교 — 동일한 yolo11m 사람 박스를 GT·OD·MLC가 공유. detector 차이로 인한 편향 제거.

GT 생성 — 헬멧: Helmet/no_helmet 둘 다 명시 라벨 사용 (3분기, 둘 다 없으면 평가 제외).


조끼: Vest 명시 라벨만 존재 → 부재 추론 사용 (Vest bbox 부재 = 미착용).

조끼 한계 — 부재 추론은 라벨 누락·가림 케이스를 미착용으로 오판 가능. 두 방식이 같은 GT를 보므로 상대 비교는 공정하나, 절대 정확도는 보수적 해석 필요.


PR Curve 평가 — 미착용 검출을 positive로 잡아 평가. MLC는 sigmoid score sweep → 곡선, OD는 단일 0/1 출력 → PR 평면 위 점 한 개.

FPS 측정 — PC 환경(yolo11m 222ms, OD 48ms, MLC 55ms/person 추론) 기준. Pi5 실측은 향후 과제.

혼동 행렬 (Confusion Matrix) — 환경별 상세



single — 1인 환경



crowd — 3인 이상 환경

읽는 법 왼쪽 위 칸 = 정탐, 오른쪽 위 칸 = 미경고(미착용을 착용으로 오판). Vest-OD crowd의 우상단 236건이 OD의 다인원 vest 약점을 보여줌.